PROYECTO INTEGRADOR

Pipeline ETL robusto con zona de cuarentena

Dominio: Retail & E-commerce omnicanal (venta física + tienda web)

Ingeniería de Datos (ATD-2602) - Unidad 2: Limpieza y Preprocesamiento de Datos
Instituto Tecnológico de Colima - Grupo 1 (LCS2) - Semestre Ago-Dic 2026
Prof. Armando Román Gallardo Heredia

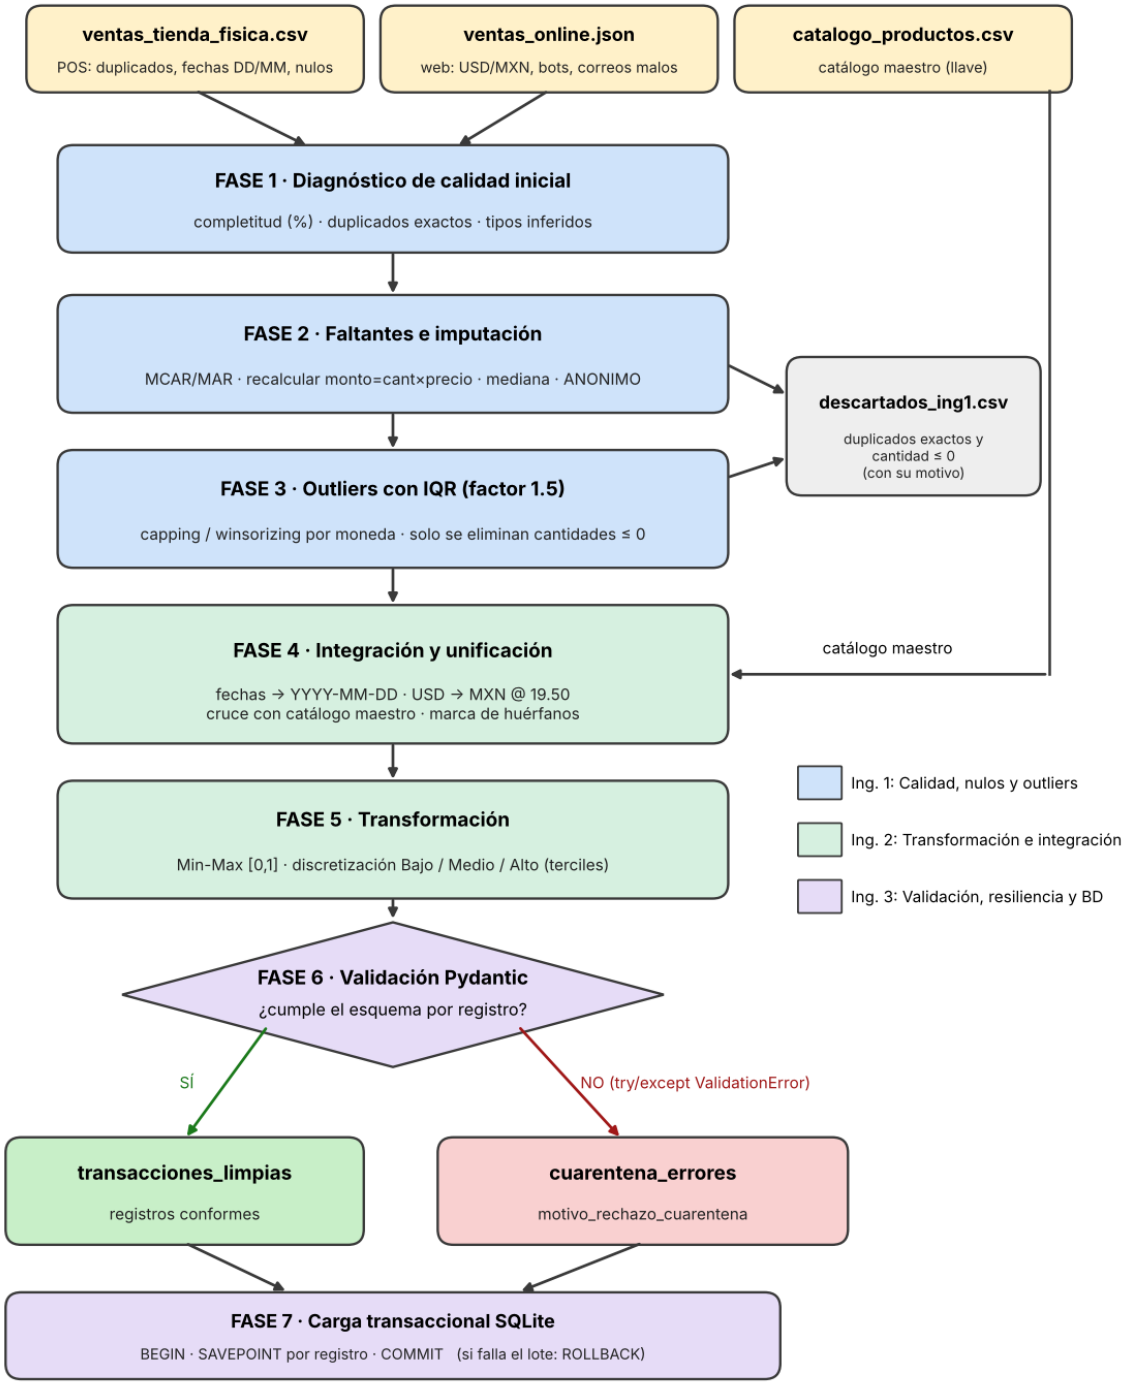
Rol	Especialidad	Integrante	Entregable clave
Ingeniero/a 1	Calidad, Nulos y Outliers	Ingeniero 1	calidad.py + reporte antes/después
Ingeniero/a 2	Transformación e Integración	Ingeniero 2	integracion.py (multifuente y normalización)
Ingeniero/a 3	Validación, Resiliencia y BD	Ingeniero 3	validacion.py + base_datos.py + pruebas de estrés

Fecha de generación: 2026-10-23

1. Objetivo y diseño del pipeline

El pipeline ingiere datos crudos e inconsistentes de tres fuentes heterogéneas (CSV de tienda física, JSON de la tienda web y catálogo maestro), diagnostica su calidad, aplica preprocesamiento estadístico, valida cada registro con Pydantic y persiste los conformes en SQLite. Los registros inválidos se aíslan en una tabla de cuarentena con su motivo, sin detener el lote. El diagrama muestra el flujo completo de las 7 fases del pipeline y qué ingeniero es responsable de cada una.

Pipeline ETL robusto con zona de cuarentena — Retail & E-commerce omnicanal



2. Resumen ejecutivo de la corrida

Indicador	Valor
Estado del pipeline	OK
Duración (s)	2.29
Filas de entrada (ambas fuentes)	1,220
Descartadas en limpieza (duplicados exactos, cantidad <= 0)	31
Registros aptos en transacciones_limpias	1,104
Registros en cuarentena_errores	85
Reconciliación (entrada = descartadas + limpias + cuarentena)	CUADRA
Integridad de la base (PRAGMA integrity_check)	ok
Tasa USD -> MXN utilizada	19.50
Factor IQR	1.50

Ningún registro se pierde en silencio: de 1,220 filas de entrada, 31 se descartaron con motivo documentado, 1,104 pasaron a la tabla limpia y 85 quedaron en cuarentena con su causa.

3. Fases 1 a 3 - Calidad, nulos y outliers (Ingeniero/a 1)

3.1 Fuente: fisica

Fase 1 - Diagnóstico inicial y comparación antes/después

Métrica	Antes	Después
Filas	620	589
Duplicados exactos	20	0
Duplicados de id_venta	20	0
Filas con algún faltante	153	0
Completitud global (%)	97.15	100

Perfil por columna (antes de transformar). 'pseudo_nulos' cuenta textos como N/A, - o s/d.

columna	dtype	tipo_inferido	nulos	pseudo_nulos	pct_faltantes	unicos	nota
id_venta	str	texto	0	0	0	600	
fecha	str	fecha_como_texto	0	0	0	135	ISO: 207 | D/M/A: 413 | otros: 0
sucursal	str	texto	0	0	0	4	
id_producto	str	texto	0	0	0	72	
cantidad	int64	numerico	0	0	0	9	
precio_unitario	float64	numerico	0	0	0	51	
monto_total	float64	numerico	32	0	5.16	240	
id_cliente	str	texto	127	0	20.48	183	
metodo_pago	str	texto	0	0	0	6	

Fase 2 - Clasificación del mecanismo de ausencia (MCAR / MAR)

Para cada columna con faltantes se prueba si la ausencia se asocia con otras variables observadas (Mann-Whitney U para numéricas, chi-cuadrada para categóricas, corrección de Bonferroni, alfa = 0.05). MAR significa que la ausencia depende de otra variable; MCAR, que no hay evidencia de dependencia. MNAR no es verificable con los datos observados y se descarta por el contexto del dominio.

columna	faltantes	pct_faltantes	clasificacion	variable_asociada	p_ajustado	recalculables_desde_otras_columnas
monto_total	32	5.1600	MCAR		1	32
id_cliente	127	20.4800	MCAR		0.3993	0

Estadísticos de las variables numéricas, antes y después

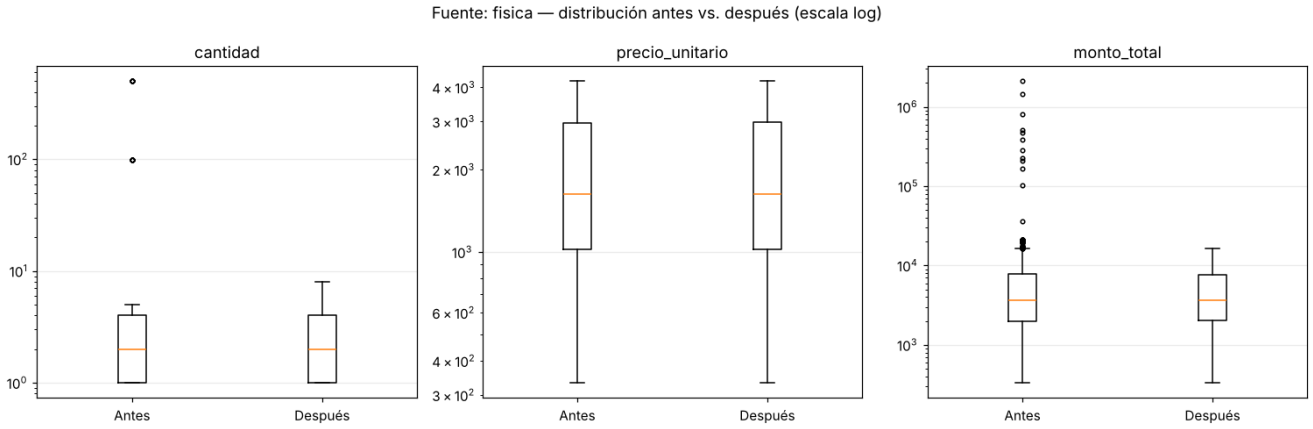
columna	momento	n	media	mediana	desv_est	minimo	p95	maximo	asimetria
cantidad	antes	620	8.42	2	49.71	-1	5	500	9.45
cantidad	despues	589	2.71	2	1.61	1	5	8	0.93
precio_unitario	antes	620	1,992.59	1,630.95	1,207.89	332.70	4,111.19	4,218.11	0.43
precio_unitario	despues	589	2,005.25	1,630.95	1,202.57	332.70	4,111.19	4,218.11	0.41
monto_total	antes	588	16,586.74	3,506.37	115,975.72	-3,632.45	17,163.45	2,109,055	14.04
monto_total	despues	589	5,332.24	3,632.45	4,555.10	332.70	16,256.27	16,256.27	1.14

cantidad: media 8.42 vs. mediana 2.00 (razón 4.21); asimetría 9.45. La distribución está sesgada a la derecha: la media se infla con extremos (bots, compras gigantes), por eso se imputa con la mediana.
precio_unitario: media 1,992.59 vs. mediana 1,630.95 (razón 1.22); asimetría 0.43. Se usa la mediana por ser robusta a valores extremos.
monto_total: media 16,586.74 vs. mediana 3,506.37 (razón 4.73); asimetría 14.04. La distribución está sesgada a la derecha: la media se infla con extremos (bots, compras gigantes), por eso se imputa con la mediana.

Fase 3 - Umbrales IQR (factor 1.5) y registros afectados

columna	grupo	n	q1	q3	lim_inf	lim_sup	capeados_inf	capeados_sup	accion
cantidad	TODAS	589	1	4	1	8	0	13	recortado
precio_unitario	MXN	589	1,025.98	2,985.89	-1,913.88	5,925.75	0	0	solo_detectado
monto_total	MXN	589	2,012.82	7,710.20	-6,533.25	16,256.27	0	34	recortado

precio_unitario solo se diagnostica (es un atributo del catálogo); cantidad y monto_total se recortan al límite (capping / winsorizing) sin eliminar la venta. Los límites de monto y precio se calculan por moneda.



Intervenciones registradas (cada una queda marcada en la columna flags_ing1)

Intervención	Registros
duplicados_exactos_eliminados	20
cantidad_no_positiva_eliminadas	11
monto_total_recalculado	31
id_cliente_anonimo	121
email_columna_ausente_en_fuente	589
monto_difiere_de_cantidad_x_precio	34
cantidad_capeados	13
monto_total_capeados	34
filas_descartadas	31

Advertencia: La fuente no trae columna de moneda: se asumió 'MXN' para todos los registros.
Advertencia: La fuente no trae la columna 'email': se etiquetó 'ANONIMO' en todas las filas.

3.2 Fuente: online

Fase 1 - Diagnóstico inicial y comparación antes/después

Métrica	Antes	Después
Filas	600	600
Duplicados exactos	0	0
Duplicados de id_venta	0	0
Filas con algún faltante	92	0
Completitud global (%)	98.53	100

Perfil por columna (antes de transformar). 'pseudo_nulos' cuenta textos como N/A, - o s/d.

columna	dtype	tipo_inferido	nulos	pseudo_nulos	pct_faltantes	unicos	nota
id_venta	str	texto	0	0	0	600	
fecha	object	fecha_como_texto	0	0	0	598	ISO: 392 | D/M/A: 0 | otros: 208
id_producto	str	texto	0	0	0	80	
cantidad	int64	numerico	0	0	0	3	
moneda	str	texto	0	0	0	2	
precio_unitario	float64	numerico	0	0	0	102	
monto_total	float64	numerico	0	0	0	237	
email	str	texto	15	5	3.33	547	
direccion_envio	str	texto	77	0	12.83	522	
estatus_pedido	str	texto	0	0	0	6	
metodo_pago	str	texto	0	0	0	4	

Fase 2 - Clasificación del mecanismo de ausencia (MCAR / MAR)

Para cada columna con faltantes se prueba si la ausencia se asocia con otras variables observadas (Mann-Whitney U para numéricas, chi-cuadrada para categóricas, corrección de Bonferroni, alfa = 0.05). MAR significa que la ausencia depende de otra variable; MCAR, que no hay evidencia de dependencia. MNAR no es verificable con los datos observados y se descarta por el contexto del dominio.

columna	faltantes	pct_faltantes	clasificacion	variable_asociada	p_ajustado	recalculables_desde_otras_columnas
email	20	3.3300	MCAR		1	0
direccion_envio	77	12.8300	MCAR		1	0

Estadísticos de las variables numéricas, antes y después

columna	momento	n	media	mediana	desv_est	minimo	p95	maximo	asimetria
cantidad	antes	600	1.58	1	0.78	1	3	3	0.88
cantidad	despues	600	1.58	1	0.78	1	3	3	0.88
precio_unitario	antes	600	1,329.49	1,025.98	1,279.99	17.06	3,960.31	4,218.11	0.79
precio_unitario	despues	600	1,329.49	1,025.98	1,279.99	17.06	3,960.31	4,218.11	0.79
monto_total	antes	600	4,978.30	1,228.72	36,737.32	17.06	8,106.56	826,360.80	19.34
monto_total	despues	600	1,963.50	1,227.12	2,073.71	17.06	7,194.45	7,409.40	1.22

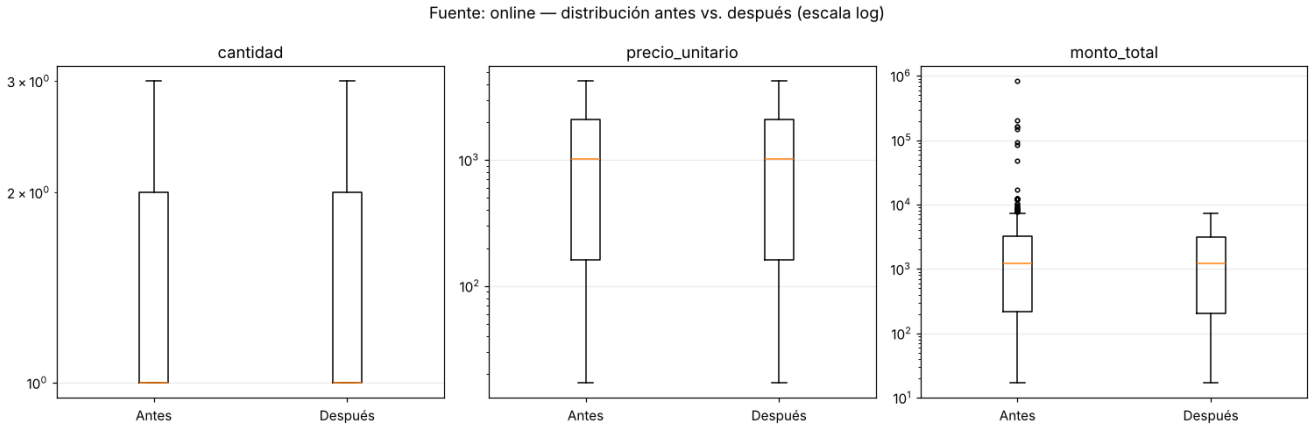
cantidad: media 1.58 vs. mediana 1.00 (razón 1.58); asimetría 0.88. Se usa la mediana por ser robusta a valores extremos.
precio_unitario: media 1,329.49 vs. mediana 1,025.98 (razón 1.30); asimetría 0.79. Se usa la mediana por ser robusta a valores extremos.
monto_total: media 4,978.30 vs. mediana 1,228.72 (razón 4.05); asimetría 19.34. La distribución está sesgada a la derecha: la media se infla con extremos (bots, compras gigantes), por eso se imputa con la mediana.

Fase 3 - Umbrales IQR (factor 1.5) y registros afectados

columna	grupo	n	q1	q3	lim_inf	lim_sup	capeados_inf	capeados_sup	accion
cantidad	TODAS	600	1	2	1	3	0	0	recortado
precio_unitario	MXN	407	1,008.15	2,966.70	-1,929.67	5,904.52	0	0	solo_detectado
precio_unitario	USD	193	51.70	153.12	-100.43	305.25	0	0	solo_detectado
monto_total	MXN	407	1,200	3,683.76	-2,525.64	7,409.40	0	28	recortado

columna	grupo	n	q1	q3	lim_inf	lim_sup	capeados_inf	capeados_sup	accion
monto_total	USD	193	59.94	178.54	-117.96	356.44	0	16	recortado

precio_unitario solo se diagnostica (es un atributo del catálogo); cantidad y monto_total se recortan al límite (capping / winsorizing) sin eliminar la venta. Los límites de monto y precio se calculan por moneda.



Intervenciones registradas (cada una queda marcada en la columna flags_ing1)

Intervención	Registros
pseudo_nulos_convertidos_a_nulo	5
id_cliente_columna_ausente_en_fuente	600
email_anonimo	20
monto_incoherente_recalculado	12
monto_difiere_de_cantidad_x_precio	44
monto_total_capeados	44

Advertencia: La fuente no trae la columna 'id_cliente': se etiquetó 'ANONIMO' en todas las filas.

4. Fases 4 y 5 - Integración y transformación (Ingeniero/a 2)

Estandarización de fechas a YYYY-MM-DD

Se aceptan fechas ISO (con o sin hora), AAAA/MM/DD, timestamps epoch (segundos o milisegundos, convertidos a hora de Colima UTC-6) y día/mes/año con / - o .; la convención para el formato con separadores es DÍA/MES/AÑO. Las fechas imposibles (31/02, mes 13) o ilegibles quedan nulas y marcadas, y la validación las envía a cuarentena.

Concepto	Registros
Total de filas	1,189
Ya en formato ISO	589
Convertidas desde DD/MM/AAAA	392
Convertidas desde epoch (timestamp)	208
Convertidas desde AAAA/MM/DD	0
Ambiguas (día y mes <= 12)	209
Fechas imposibles	0
Formato no reconocido	0
Nulas	0

Conversión de moneda y cruce con el catálogo maestro

Concepto	Valor
Paridad oficial USD -> MXN	19.50
Filas convertidas de USD a MXN	193
Monedas no reconocidas (se rechazan en Fase 6)	0
Productos en el catálogo (tras limpiar llaves)	50
Llaves duplicadas / nulas en el catálogo	0 / 0
Transacciones huérfanas (producto no existe en catálogo)	60
Huérfanos por llave nula	0
Productos distintos huérfanos	51

Escalamiento Min-Max y discretización del importe

monto_total (MXN) se normaliza a [0, 1] con x' = (x - min) / (max - min); mínimo = 332.67, máximo = 16,256.27. El importe se discretiza en tres segmentos por terciles (cuantiles 33.3 % y 66.7 %): Bajo hasta 2,012.82 MXN, Medio hasta 4,097.96 MXN y Alto por encima. Los terciles producen segmentos equilibrados y no dependen de umbrales arbitrarios en una distribución asimétrica.

Segmento	Registros
Bajo	399
Medio	396
Alto	394

5. Fases 6 y 7 - Validación, cuarentena y base de datos (Ingeniero/a 3)

Validación con Pydantic

Cada registro se valida de forma independiente contra el esquema VentaLimpia (BaseModel con restricciones de campo, @field_validator y un @model_validator para la regla monto_total = cantidad x precio_unitario con tolerancia del 1 %). Un ValidationError se captura con try/except y el registro se desvía a cuarentena con la columna motivo_rechazo_cuarentena; el lote nunca se detiene.

Concepto	Valor
Registros validados	1,189
Aptos	1,104
A cuarentena	85
% en cuarentena	7.15

Campo	Regla
fuente	solo 'fisica' u 'online'
id_venta / id_producto	obligatorios; solo A-Z, 0-9, '_', '-', '.'
fecha	formato ISO estricto YYYY-MM-DD, entre 2000-01-01 y hoy
cantidad	entero entre 1 y 10,000
precio_unitario / monto_total	decimales finitos mayores que 0
moneda	solo MXN (tras la conversión)
email	formato válido o la etiqueta controlada ANONIMO
es_huerfano	debe ser falso (el producto existe en el catálogo)
monto_total_minmax	entre 0 y 1
segmento_monto	Bajo, Medio o Alto
regla de negocio	monto_total ~ cantidad x precio_unitario (1 %), salvo discrepancia ya documentada por el Ing. 1

Causas de cuarentena (un registro puede fallar por más de un campo)

campo	causa	registros
es_huerfano	llave huérfana: el id_producto no existe en el catálogo maestro	60
email	correo con formato inválido	28

Ejemplos de registros en cuarentena_errores (por tipo de causa)

fuente	id_venta	etapa	motivo_rechazo_cuarentena
fisica	POS-2026-0017	VALIDACION_PYDANTIC	es_huerfano: llave huérfana: el id_producto no existe en el catálogo maestro [valor recibido: True]
fisica	POS-2026-0072	VALIDACION_PYDANTIC	es_huerfano: llave huérfana: el id_producto no existe en el catálogo maestro [valor recibido: True]
online	WEB-00004	VALIDACION_PYDANTIC	email: correo con formato inválido [valor recibido: 'correo_invalido.com']
online	WEB-00083	VALIDACION_PYDANTIC	email: correo con formato inválido [valor recibido: 'sin_arroba_dominio.org']

Carga transaccional a SQLite

La carga ocurre dentro de una sola transacción (BEGIN ... COMMIT). Cada INSERT usa su propio SAVEPOINT: si la base rechaza un registro (restricción CHECK, tipo, etc.) solo ese registro revierte y se desvía a cuarentena con etapa ERROR_BD. Si falla algo catastrófico se ejecuta ROLLBACK y la base queda como estaba. La carga reemplaza el contenido completo, por lo que correr el pipeline varias veces no duplica filas.

Tabla	Columnas
transacciones_limpias	id_registro (PK), fuente, id_venta, fecha, id_producto, nombre_producto, categoria, cantidad, precio_unitario, monto_total, moneda, moneda_original, id_cliente, email, metodo_pago, sucursal, estatus_pedido, monto_total_minmax, segmento_monto, flags_ing1, fila_origen, fecha_carga. Restricciones CHECK en fecha, cantidad, precios, moneda, minmax y segmento.
cuarentena_errores	id_cuarentena (PK), fuente, id_venta, fila_origen, etapa, motivo_rechazo_cuarentena (NOT NULL), datos_originales_json, fecha_carga

Verificación sobre la BD	Resultado
Filas en transacciones_limpias	1,104
Filas en cuarentena_errores	85
Monto total cargado (MXN)	4,700,386.25
Por fuente	{"fisica": 562, "online": 542}
Por segmento	{"Alto": 391, "Bajo": 335, "Medio": 378}
Cuarentena por etapa	{"VALIDACION_PYDANTIC": 85}
integrity_check	ok

6. Resiliencia: pruebas de estrés con datos corruptos

Se inyectaron 23 escenarios de corrupción (ruido masivo, archivos vacíos o truncados, fuentes inexistentes, fechas imposibles, SQL injection, valores extremos, monedas raras, columnas faltantes, duplicados masivos, BD inaccesible, entre otros) y se ejecutó el pipeline completo en cada uno. Resultado: 23 de 23 escenarios aprobados. Criterios: el pipeline no lanza excepciones no controladas, la reconciliación de filas cuadra y la integridad de la base es correcta.

escenario	descripcion	resultado	estado_pipeline	en_limpias	en_cuarentena	reconciliacion_cuadra
01_base_sin_corrupcion	Datos de referencia sin dañar	PASA	OK	1,104	85	Sí
02_ruido_masivo_35pct	35 % de las celdas reemplazadas por basura (emoji, inf, SQL, 5 000 caracteres, tipos raros)	PASA	OK	235	927	Sí
03_ruido_extremo_85pct	85 % de las celdas corruptas en ambas fuentes	PASA	OK	2	1,118	Sí
04_solo_encabezados	CSV físico con encabezados y 0 filas	PASA	OK	542	58	Sí
05_csv_0_bytes	Archivo CSV vacío (0 bytes)	PASA	PARCIAL	542	58	Sí
06_json_truncado	JSON online cortado a la mitad	PASA	PARCIAL	562	27	Sí
07_online_inexistente	El archivo online no existe	PASA	PARCIAL	562	27	Sí
08_ambas_fuentes_rotas	CSV vacío + JSON inválido	PASA	ABORTADO			
09_catalogo_inexistente	No existe catalogo_productos.csv	PASA	ABORTADO			
10_catalogo_sin_llave	Catálogo sin columna de llave reconocible	PASA	ABORTADO			
11_todo_huerfano	Ningún producto existe en el catálogo	PASA	OK	0	1,189	Sí
12_fechas_imposibles	Fechas 31/02, mes 13, '0000-00-00', 'ayer', vacías	PASA	OK	542	647	Sí
13_inyeccion_sql_unicode	SQL injection y emojis en SKU, correo, ticket y método de pago	PASA	OK	964	225	Sí
14_valores_extremos	1e12, 1e308, -inf, enteros de 40 dígitos, precios negativos	PASA	OK	955	236	Sí
15_monedas_raras	EUR, BTC, '$', '???', nulas, 'Dólares'	PASA	OK	764	425	Sí
16_columnas_faltantes	Faltan precio, total, correo, cantidad y moneda	PASA	OK	0	1,189	Sí
17_columnas_duplicadas	Encabezados repetidos, con espacios y columnas basura	PASA	OK	1,104	85	Sí
18_encoding_latin1	CSV guardado en Latin-1 con ñ y acentos	PASA	OK	1,104	85	Sí
19_catalogo_duplicados_nulos	Catálogo con llaves duplicadas, nulas y 'N/A'	PASA	OK	1,104	85	Sí
20_lote_duplicado_x5	Cada registro repetido 5 veces (reenvíos del POS)	PASA	OK	1,104	85	Sí
21_json_anidado_jsonl	JSON Lines con objetos anidados y listas de ítems	PASA	OK	562	77	Sí
22_bd_inaccesible	La ruta de la BD es un directorio (no se puede abrir)	PASA	CARGA_REVERTIDA			
23_epoch_extremos	Timestamps epoch en milisegundos, negativos, gigantes, booleanos y listas	PASA	OK	880	309	Sí

7. Conclusiones, supuestos y limitaciones

- El pipeline completa las 7 fases de inicio a fin, aísla los registros inválidos con trazabilidad auditable y conserva la reconciliación exacta de filas.

- El capping con IQR 1.5 sobre cantidades enteras pequeñas puede recortar compras legítimas; es el método que pide la guía y el factor es configurable.

- Las fechas con separadores se interpretan como DÍA/MES/AÑO (convención mexicana); las ambiguas se cuantifican en la sección 4.

- Una moneda nula se asume MXN, y la tienda física se asume en MXN (su columna se llama monto_total_mxn); son supuestos, no hechos.

- Los pedidos online CANCELADO o DEVUELTO se conservan en transacciones_limpias con su estatus_pedido (no son datos inválidos); quien calcule ingresos debe filtrarlos.

- Cuando el total de un pedido no coincide con unidades x precio (totales inflados por bots), se recalcula con esa identidad; el hecho queda en la bandera monto_total:recalculado_por_incoherencia.

- La fuente online no trae id_cliente y la física no trae correo: esas columnas se etiquetan ANONIMO en toda la fuente (bandera fuente_sin_columna). La dirección de envío no se carga por ser dato personal sin uso analítico.

- MNAR no es verificable con los datos observados; se descarta por conocimiento del dominio.

- Min-Max y terciles se calculan sobre todos los registros integrados antes de la validación, siguiendo el orden de fases de la guía.

Reglas de negocio completas y su justificación estadística: REGLAS_DE_NEGOCIO.md.